



**École d'Ingénieurs du Littoral-Côte-d'Opale**

**Université du Littoral-Côte-d'Opale**

Laboratoire LISIC



**Ingénierie des Systèmes Complexes (ISC)**

---

# **Validation expérimentale de méthodes de filtrage bayésien et ensembliste appliquées à la détection et au suivi de déchets flottants**

---

Rapport de fin d'études Master ISC

Présenté par :

**Khalil Tarhda**

**Encadrants :**

**M. Régis Lherbier** Maître de conférences - l'Université du Littoral Côte-d'Opale (LISIC)

**M. Mohamed Fnadi** Maître de conférences - l'Université du Littoral Côte-d'Opale (LISIC)

Année universitaire 2025–2026

## Remerciements

En premier lieu, je tiens à remercier Monsieur **Abderrahman Bouhamidi**, responsable du Master Ingénierie des Systèmes Complexes, pour la qualité de la formation dispensée et son investissement tout au long de ce cursus.

Je tiens ensuite à exprimer ma profonde gratitude à mes deux encadrants, **M. Régis Lherbier** et **M. Mohamed Fnadi**, pour leur encadrement rigoureux, leur disponibilité et leurs précieux conseils tout au long de ce projet.

Je remercie également chaleureusement l'ensemble de l'équipe du laboratoire **LISIC**, ainsi que mes collègues, pour leur accueil, leur aide au quotidien et l'ambiance de travail conviviale et stimulante qu'ils m'ont offerte.

Enfin, je tiens à exprimer ma sincère gratitude à mes parents, **Lhoussain Tarhda** et **Souad Rachidi**, sans qui je n'en serais pas là aujourd'hui. Leur soutien indéfectible, leurs sacrifices et leur confiance en moi ont été le moteur de tout mon parcours. Que ce travail soit le témoignage de ma profonde reconnaissance et de mon amour pour eux. Mes remerciements vont aussi à mon frère **Adam** et à mes deux sœurs **Malak** et **Loubna**, pour leur présence, leurs encouragements et leur bienveillance, ainsi qu'à mes amis, pour leur soutien moral et les moments de partage qui ont rendu ce chemin plus agréable.

## Résumé

Ce stage de Master 2, réalisé au laboratoire LISIC (équipe EDyFI) de l'Université du Littoral Côte-d'Opale, porte sur l'étude de faisabilité d'un capteur LiDAR 3D (Ouster OS1) couplé à une centrale inertielle (IMU) en milieu marin pour la détection et le suivi de déchets marins flottants. Un algorithme a été développé, intégrant l'extraction d'une région d'intérêt (ROI), la segmentation par distance radiale adaptative, l'extraction clusters, ainsi que l'évaluation de plusieurs algorithmes de suivi multi-objets (MOT) probabilistes et ensemblistes pour réaliser la trajectographie des objets flottants. Le système a été validé sur des acquisitions réelles avec différents types d'objets flottants dans le canal de Calais.

**Mots-clés :** LiDAR 3D, Détection, Suivi d'objets, Filtre particulaire par intervalles, Objets flottants, MATLAB, Filtre de Kalman, Monte-Carlo.

---

## Abstract

This Master's (M2) internship, carried out at the LISIC laboratory (EDyFI team) of the Université du Littoral Côte d'Opale, investigates the feasibility of using a 3D LiDAR sensor (Ouster OS1) coupled with an inertial measurement unit (IMU) to detect and track floating debris. A processing pipeline was developed, including region-of-interest (ROI) extraction, adaptive radial-distance segmentation and cluster extraction, and four probabilistic and set-membership multi-object tracking (MOT) filters were implemented and compared. The system was evaluated on real acquisitions of three floating objects in the Calais canal.

**Keywords :** 3D LiDAR, Detection, Object Tracking, Interval Particle Filter, Floating Objects, MATLAB, Kalman Filter, Monte-Carlo.

# Table des matières

|                                                                          |          |
|--------------------------------------------------------------------------|----------|
| <b>Introduction générale</b>                                             | <b>1</b> |
| <b>1 Contexte du travail et cahier des charges</b>                       | <b>2</b> |
| 1.1 Présentation de l'organisme d'accueil . . . . .                      | 2        |
| 1.1.1 L'Université du Littoral Côte d'Opale (ULCO) . . . . .             | 2        |
| 1.1.2 Le laboratoire LISIC . . . . .                                     | 2        |
| 1.2 Cadre du stage . . . . .                                             | 2        |
| 1.3 État de l'art sur les méthodes de détection et de tracking . . . . . | 3        |
| 1.3.1 Méthodes de détection . . . . .                                    | 3        |
| 1.3.2 Méthodes de suivi (Tracking) . . . . .                             | 3        |
| 1.4 Cahier des charges (Objectifs du projet) . . . . .                   | 4        |
| <b>2 Conception des algorithmes</b>                                      | <b>5</b> |
| 2.1 Le capteur LiDAR 3D et structure des données . . . . .               | 5        |
| 2.1.1 Principe de fonctionnement . . . . .                               | 5        |
| 2.1.2 Le capteur Ouster OS1 . . . . .                                    | 5        |
| 2.1.3 Système de coordonnées sphériques . . . . .                        | 6        |
| 2.1.4 Formats de fichiers d'acquisition . . . . .                        | 7        |
| 2.1.5 La centrale inertielle (IMU) intégrée . . . . .                    | 7        |
| 2.2 Détection d'objets . . . . .                                         | 9        |
| 2.2.1 Spécificité de la détection dans différents milieux . . . . .      | 9        |
| 2.2.2 Calibration et projection des données . . . . .                    | 10       |
| 2.2.3 Extraction de la Région d'Intérêt (ROI) . . . . .                  | 11       |
| 2.2.4 Segmentation par distance radiale adaptative . . . . .             | 12       |
| 2.2.5 Extraction des boîtes englobantes des objets . . . . .             | 13       |
| 2.2.6 Synthèse algorithmique : Le détecteur complet . . . . .            | 17       |
| 2.3 Suivi multi-objets (MOT) . . . . .                                   | 17       |
| 2.3.1 Principe d'association par Distance de Mahalanobis . . . . .       | 18       |
| 2.3.2 Filtre de Kalman . . . . .                                         | 20       |

|          |                                                                           |           |
|----------|---------------------------------------------------------------------------|-----------|
| 2.3.3    | Filtre de Kalman ensembliste (UBIKF) . . . . .                            | 23        |
| 2.3.4    | Filtre particulaire (Monte-Carlo) . . . . .                               | 25        |
| 2.3.5    | Filtre particulaire par intervalles (Box Particle Filter) . . . . .       | 27        |
| <b>3</b> | <b>Validation expérimentale</b>                                           | <b>29</b> |
| 3.1      | Environnement et protocole expérimental . . . . .                         | 29        |
| 3.2      | Résultats expérimentaux de suivi et détection . . . . .                   | 30        |
| 3.2.1    | Validation des méthodes probabilistes . . . . .                           | 30        |
| 3.2.2    | Validation des méthodes ensemblistes (par intervalles) . . . . .          | 32        |
| 3.3      | Analyse cinématique détaillée (Objet ID 1) . . . . .                      | 34        |
| 3.3.1    | Comparaison spatiale . . . . .                                            | 34        |
| 3.3.2    | Validation de la vitesse et de l'accélération . . . . .                   | 35        |
| 3.4      | Analyse critique des modèles . . . . .                                    | 36        |
| 3.5      | Évaluation quantitative du suivi par la métrique de cardinalité . . . . . | 38        |
|          | <b>Conclusion générale, retour d'expérience et perspectives</b>           | <b>41</b> |
|          | <b>Bibliographie</b>                                                      | <b>43</b> |

# Introduction générale

## Contexte

Le milieu marin est aujourd’hui confronté à une crise environnementale majeure, accentuée par la prolifération des macro-déchets et des débris flottants. La détection précoce, la trajectographie et la collecte automatisée de ces polluants constituent des défis écologiques et technologiques prioritaires. Dans le domaine de la robotique marine et des véhicules autonomes, la capacité d’un système à percevoir son environnement de manière fiable est essentielle. Pour s’affranchir des difficultés liées aux reflets de l’eau ou aux variations de luminosité, les capteurs actifs, et plus particulièrement le LiDAR 3D (*Light Detection and Ranging*), s’imposent comme une solution technologique robuste. En mesurant le temps de vol d’impulsions laser ainsi que l’intensité du signal de retour (réflectivité), le LiDAR fournit une cartographie tridimensionnelle précise de l’environnement sous forme de nuages de points.

## Problématique et verrous technologiques

Traiter les données d’un LiDAR 3D à des fins de suivi d’objets en milieu marin soulève d’importants verrous scientifiques. En effet, la surface de l’eau est constamment agitée par le vent et les vagues, ce qui génère un très grand nombre de fausses détections (faux positifs) assimilables à un bruit de mesure important. Enfin, le problème du suivi multi-objets (*Multi-Object Tracking - MOT*) impose de résoudre conjointement l’estimation cinématique de l’état des déchets (position, vitesse, accélération) et l’association robuste des données, afin de relier chaque nouvelle détection à la bonne trajectoire sans croisement d’identifiants. Pour répondre à ces défis technologiques, le présent rapport s’articule autour de trois chapitres principaux :

- **Le Chapitre 1** présentera le contexte du stage, l’état de l’art des solutions de perception maritime, ainsi que le cahier des charges technique.
- **Le Chapitre 2** sera consacré à la conception théorique de notre architecture logicielle, détaillant l’algorithme de traitement LiDAR depuis la détection jusqu’aux algorithmes de suivi multi-objets (MOT) des déchets flottants marins.
- **Le Chapitre 3** exposera la validation expérimentale de nos développements en milieu aquatique, en proposant une analyse comparative des performances cinématiques et de la gestion des incertitudes.

# Chapitre 1 : Contexte du travail et cahier des charges

Ce premier chapitre a pour objectif de situer le cadre professionnel et scientifique dans lequel s’est déroulé ce projet de fin d’études. Nous y présenterons brièvement l’organisme d’accueil et le laboratoire de recherche, avant de dresser un état de l’art des solutions existantes pour la perception en milieu marin. Enfin, nous définirons formellement le cahier des charges et les objectifs technologiques fixés pour ce stage.

## 1.1 Présentation de l’organisme d’accueil

### 1.1.1 L’Université du Littoral Côte d’Opale (ULCO)

L’Université du Littoral Côte d’Opale (ULCO), fondée en 1991 dans le cadre du plan *Université 2000*, est une université publique française des Hauts-de-France. Elle est implantée sur quatre campus : Dunkerque, Calais, Boulogne-sur-Mer et Saint-Omer, et accueille environ 10 000 étudiants avec plus de 100 diplômes accrédités. L’ULCO se distingue par sa dimension humaine et son engagement dans la recherche au travers de 14 unités de recherche réparties en trois pôles disciplinaires.

### 1.1.2 Le laboratoire LISIC

Le Laboratoire d’Informatique Signal et Image de la Côte d’Opale (LISIC — UR 4491), créé en 2010 et localisé sur le campus de Calais (Maison de la Recherche Blaise Pascal), est le laboratoire du numérique de l’ULCO. Il regroupe 75 membres dont 42 enseignants-chercheurs permanents, répartis en 5 équipes de recherche et 3 groupes projet, couvrant les domaines du traitement du signal, de l’image et de l’informatique. Ce stage a été réalisé au sein de l’équipe **EDyFI** (*Estimation Dynamique par Fusion d’Informations*), spécialisée dans la fusion de capteurs et les méthodes d’estimation pour la localisation et le suivi d’objets.

## 1.2 Cadre du stage

Ce stage de Master 2, d’une durée de 7 mois (à partir de mars 2026), a été réalisé au sein du laboratoire LISIC — UR4491, équipe EDyFI (*Estimation Dynamique et Fusion d’Informations*), sur le campus de Calais de l’ULCO. Il a été encadré par M. Régis Lherbier et M. Mohamed Fnadi,

enseignants-chercheurs spécialisés en traitement du signal et fusion de capteurs. L'intitulé officiel du stage est : “*Validation expérimentale de méthodes de filtrage bayésien et ensembliste appliquées à la détection et au suivi de déchets flottants*”. La mission principale consistait à développer et valider l'algorithme de détection et de suivi d'objets flottants (comme les déchets plastiques - bouteilles, sacs, filets de pêches....) en milieu aquatique, en exploitant les données télémétriques d'un capteur LiDAR 3D Ouster OS1 couplé à une centrale inertielle IMU.

## 1.3 État de l'art sur les méthodes de détection et de tracking

### 1.3.1 Méthodes de détection

La détection d'objets en environnement marin a longtemps reposé sur des systèmes de vision par caméra RGB ou stéréoscopique. Ces approches passives, bien que performantes en conditions favorables, restent très sensibles aux variations d'éclairage, au scintillement de l'eau et aux intempéries, ce qui limite leur fiabilité en conditions réelles [1]. L'essor du capteur actif LiDAR 3D a ouvert de nouvelles perspectives pour une perception tridimensionnelle robuste, ce qui a encouragé la communauté scientifique à constituer de nouvelles bases de données dédiées à la perception en milieu non structuré de grande envergure [2].

### 1.3.2 Méthodes de suivi (Tracking)

Côté suivi de cibles (*tracking*), les méthodes probabilistes classiques telles que le filtre de Kalman standard [3] ou les filtres particuliers classiques [4] supposent des mesures précises et des bruits suivant une loi gaussienne. Ces hypothèses sont difficilement vérifiables en milieu marin, où l'agitation de la surface de l'eau génère des incertitudes de mesure biaisées et des détections aberrantes (faux positifs). Pour contourner ces limites mathématiques, de récentes avancées se sont tournées vers les approches ensemblistes basées sur l'analyse par intervalles. Dans le cadre du filtrage de Kalman, les travaux de Xiong et al. (2013) [5] ont amélioré le filtre de Kalman par intervalles grâce à la propagation de contraintes. L'UBIKF (*Upper Bound Interval Kalman Filter*) a ensuite été optimisé par Tran et al. (2021) [6] afin de calculer une borne supérieure garantie de la matrice de covariance, limitant ainsi le pessimisme inhérent au calcul par intervalles. Dans la même dynamique, pour les méthodes de Monte-Carlo, Abdallah et al. (2008) [7] ont formulé le concept de filtre particulier par boîtes (*Box Particle Filter*). Cette méthode remplace les particules ponctuelles classiques par des boîtes, permettant de modéliser explicitement les incertitudes avec un nombre

réduit d'entités. Des travaux très récents, notamment ceux de Fnadi et Lherbier (SCAN 2025) [8], exploitent et adaptent ces concepts sous forme de filtres particuliers par des boîtes spécifiquement pensés pour le suivi d'objets flottants, offrant une robustesse inédite face aux perturbations maritimes.

## 1.4 Cahier des charges (Objectifs du projet)

Afin de répondre à la problématique posée, les objectifs et exigences de ce projet de fin d'études s'articulent autour des axes méthodologiques et techniques suivants :

- **Campagnes d'acquisition expérimentales** : organisation et réalisation de collectes de données sur le terrain en milieux aquatiques réels (lac et environnement marin). L'objectif est de constituer un jeu de données représentatif capturant la dynamique naturelle sur divers déchets flottants réels.
- **Exploitation des données capteurs** : traitement des données brutes issus du LiDAR *Ouster OS1* (matrice tensorielle, nuages de points 3D) couplés aux mesures de la centrale inertielle (IMU) pour la calibration et projection des données dans le repère monde.
- **Environnement de développement et outils** : conception du pipeline de perception sous l'environnement MATLAB [9] avec les toolbox 3D-LIDAR. L'utilisation de la boîte à outils INTLAB [10] est imposée pour garantir la fiabilité et la rigueur mathématique des calculs par intervalles lors des phases d'estimation.
- **Développement du module de détection** : implémentation d'un algorithme robuste incluant le filtrage de l'agitation de surface via une segmentation par distance radiale brute adaptative et l'extraction géométrique de boîtes englobantes.
- **Développement du module de suivi multi-objets (MOT)** : implémentation algorithmique de quatre architectures d'estimation d'état (filtre de Kalman classique, filtre de Kalman ensembliste UBIKF, filtre particulière classique et Box Particle Filter) pour estimer la cinématique des objets malgré les pertes de détection.
- **Validation et analyse comparative** : évaluation de la robustesse des algorithmes face aux perturbations de l'environnement aquatique, suivie d'une comparaison critique des performances (précision, gestion des incertitudes, temps de calcul) des approches probabilistes et ensemblistes.
- **Livrables attendus** : une architecture logicielle MATLAB/INTLAB fonctionnelle, modulaire et documentée, un rapport de stage justifiant les choix théoriques par la validation expérimentale, et une présentation des résultats lors de la soutenance.

## Chapitre 2 : Conception des algorithmes de détection et de suivi des déchets flottants

Ce chapitre détaille l'ensemble du pipeline logiciel développé sous l'environnement MATLAB au cours de ce stage. Dans un premier temps, nous analyserons la structure tensorielle des données issues du capteur LiDAR 3D. Ensuite, nous expliciterons notre méthode de détection, incluant la correction dynamique d'inclinaison et la segmentation par distance radiale adaptative. Enfin, nous décrirons les fondements mathématiques des quatre algorithmes de suivi multi-objets (MOT) développés et évalués.

### 2.1 Le capteur LiDAR 3D et structure des données

#### 2.1.1 Principe de fonctionnement

Le LiDAR (*Light Detection and Ranging*) est un capteur actif qui mesure des distances en émettant des impulsions laser et en mesurant leur temps de vol (*Time of Flight* — ToF). Pour une impulsion se propageant à la vitesse de la lumière  $c$ , la distance  $\rho$  jusqu'à l'obstacle est donnée par :

$$\rho = \frac{c \cdot \Delta t}{2} \quad (2.1)$$

où  $\Delta t$  est le temps écoulé entre l'émission et la réception de l'impulsion. En répétant cette mesure sur plusieurs faisceaux laser répartis verticalement et en faisant tourner l'ensemble à 360°, le LiDAR génère une cartographie tridimensionnelle dense de l'environnement appelée nuage de points.

#### 2.1.2 Le capteur Ouster OS1

Le capteur utilisé dans ce stage est L'**Ouster OS1**, un LiDAR 3D à 128 canaux (faisceaux laser) disposés verticalement avec un angle d'élévation. Il tourne à une fréquence de 10 ou 20 Hz et produit jusqu'à 2 621 440 points par seconde (1 310 720 dans la configuration utilisée, 1024 colonnes à 10 Hz). Chaque faisceau est identifié par son angle d'élévation  $\varphi$  fixe, tandis que l'angle azimutal  $\theta$  varie continûment avec la rotation mécanique du capteur.




FIGURE 2.1 – LiDAR 3D *Ouster OS1-128* : repère sphérique  $(\theta, \varphi, \rho)$  et IMU intégrée.

## 2.1.3 Système de coordonnées sphériques

### 2.1.3.1 Représentation tensorielle

La structure native des données télémétriques Ouster est **tensorielle** : le nuage de points brut est organisé en une matrice de dimensions  $H \times W$  télémétriques, où :

- $H$  = nombre de canaux laser (128 pour l'OS1) — correspond à l'axe d'élévation  $\varphi$
- $W$  = nombre de colonnes azimutales par révolution (512, 1024 ou 2048 selon la résolution) correspond à l'axe azimutal  $\theta$

Chaque cellule  $(i, j)$  de cette matrice contient un triplet de mesures :

$$\mathbf{M}(i, j) = (\rho_{i,j}, I_{i,j}, t_{i,j}) \quad (2.2)$$


où  $\rho_{i,j}$  est la distance mesurée (range),  $I_{i,j}$  l'intensité de retour du faisceau, et  $t_{i,j}$  l'horodatage de la mesure. Cette organisation en grille régulière est un avantage majeur : elle permet d'appliquer des opérations matricielles vectorisées efficaces sous MATLAB, sans avoir à parcourir le nuage point par point. Les angles n'apparaissent pas dans les paquets bruts : l'élévation  $\varphi_i$  est propre à chaque canal laser  $i$  et l'azimut  $\theta_j$  à chaque colonne  $j$ , tous deux fournis par le fichier de calibration JSON. En associant ces angles à la distance mesurée, chaque cellule se ramène au triplet sphérique  $(\varphi_i, \theta_j, \rho_{i,j})$  représenté sur la Figure 2.2.

### 2.1.3.2 Conversion en coordonnées cartésiennes

À partir des coordonnées sphériques  $(\rho, \theta, \varphi)$ , les coordonnées cartésiennes  $(x, y, z)$  de chaque point sont obtenues par :

$$\begin{cases} x = \rho \cos \varphi \cos \theta \\ y = \rho \cos \varphi \sin \theta \\ z = \rho \sin \varphi \end{cases} \quad (2.3)$$

où  $\theta \in [0^\circ, 360^\circ]$  est l'angle azimutal et  $\varphi \in [-21,5^\circ, +21,43^\circ]$  l'angle d'élévation.

FIGURE 2.2 – Représentation tensorielle des trames LiDAR en coordonnées sphériques  $(\varphi, \theta, \rho)$ .

### 2.1.4 Formats de fichiers d'acquisition

Lors d'une acquisition avec le capteur *Ouster OS1*, deux types de fichiers sont produits :

- **Fichier PCAP** (*Packet Capture*) : enregistrement brut des paquets UDP émis par le capteur sur le réseau. Chaque paquet contient une ou plusieurs colonnes azimutales de la matrice  $H \times W$  avec les valeurs brutes de range, intensité et horodatage. C'est le fichier principal contenant la totalité des nuages de points de l'acquisition.
- **Fichier JSON** (métadonnées) : fichier de configuration du capteur généré automatiquement. Il contient les paramètres de calibration indispensables à la reconstruction 3D.

### 2.1.5 La centrale inertielle (IMU) intégrée

Afin de compléter la cartographie spatiale fournie par les faisceaux laser, le capteur *Ouster OS1* embarque une centrale à inertie (IMU - *Inertial Measurement Unit*) à 6 degrés de liberté (6-DOF). Ce composant interne est synchronisé avec le balayage LiDAR (partageant la même horloge matérielle) et fournit des données cinématiques à une fréquence d'échantillonnage élevée (jusqu'à 100 Hz).

L'IMU se compose de deux sous-systèmes micro-électromécaniques (MEMS) fournissant les données brutes de la plateforme selon le repère local  $(X, Y, Z)$  du capteur :

- **Un accéléromètre triaxial** : Il mesure l'accélération linéaire spécifique subie par le capteur, exprimée en mètres par seconde au carré ( $m/s^2$ ) ou en facteur de gravité terrestre ( $g$ ).
- **Un gyroscope triaxial** : Il mesure la vitesse angulaire de rotation de la plateforme autour de ses trois axes, exprimée en radians par seconde ( $rad/s$ ).

Mathématiquement, à un instant  $t$ , les vecteurs de mesures brutes délivrés par l'IMU sont modélisés par les équations cinématiques suivantes :

$$\mathbf{a}_{mes} = \begin{bmatrix} a_x \\ a_y \\ a_z \end{bmatrix} = \mathbf{a}_{vrai} - \mathbf{g} + \mathbf{b}_a + \boldsymbol{\eta}_a \quad \text{et} \quad \boldsymbol{\omega}_{mes} = \begin{bmatrix} \omega_x \\ \omega_y \\ \omega_z \end{bmatrix} = \boldsymbol{\omega}_{vrai} + \mathbf{b}_\omega + \boldsymbol{\eta}_\omega \quad (2.4)$$

où :

- L'indice *mes* désigne la grandeur mesurée par le capteur, tandis que l'indice *vrai* désigne la grandeur cinématique physique réelle.
- $\mathbf{g} \approx [0; 0; -9,81]^T$  est le vecteur de gravité terrestre projeté dans le repère local du capteur.
- $\mathbf{b}_a$  et  $\mathbf{b}_\omega$  modélisent les biais statiques (dérives d'offset). Contrairement au bruit, le biais est une erreur constante ou à variation très lente (basse fréquence) qui décale la valeur moyenne de la mesure. Il nécessite généralement une calibration pour être compensé.
- $\boldsymbol{\eta}_a$  et  $\boldsymbol{\eta}_\omega$  désignent les bruits de mesure. À l'inverse du biais, ce sont des fluctuations aléatoires et rapides (haute fréquence) de moyenne nulle, généralement modélisées sous forme de bruits blancs gaussiens, qui peuvent être atténuées par filtrage.

Afin de garantir l'horizontalité du nuage de points par rapport au plan d'eau, l'inclinaison du capteur (roulis  $\phi$ , tangage  $\theta$ ) doit être compensée. En considérant l'accélération propre du système d'acquisition comme négligeable devant la gravité, l'accéléromètre mesure directement la projection du vecteur  $\mathbf{g}$  sur ses axes  $(a_x, a_y, a_z)$ . Cette propriété statique permet de déduire l'inclinaison absolue du capteur à l'aide des équations trigonométriques suivantes :

$$\phi = \text{atan2}(a_y, a_z) \quad \text{et} \quad \theta = \text{atan2}\left(-a_x, \sqrt{a_y^2 + a_z^2}\right) \quad (2.5)$$

D'autre part, l'accéléromètre ne peut pas mesurer la rotation autour de l'axe vertical (la gravité y étant parallèle). Le lacet ( $\psi$ ), tout comme le suivi des variations d'orientation très rapides, est donc obtenu par l'intégration temporelle des vitesses angulaires  $(\omega_x, \omega_y, \omega_z)$  fournies par le gyroscope :

$$\psi_t = \psi_{t-1} + \omega_z \Delta t \quad (2.6)$$

C'est cette complémentarité mécanique fondamentale qui est exploitée à l'étape suivante pour estimer l'attitude du capteur et corriger dynamiquement l'inclinaison des nuages de points LiDAR.

## 2.2 Détection d'objets

La perception de l'environnement s'articule autour d'un pipeline séquentiel de traitement de données. Ce flux de travail, illustré par la Figure 2.3, part de l'acquisition des paquets réseau bruts pour aboutir à l'identification géométrique des objets à la surface de l'eau. Chaque étape est conçue pour réduire l'espace de recherche avant l'étape finale d'estimation d'état.




FIGURE 2.3 – Logigramme global du pipeline de perception adaptatif (Marin / Terrestre).

### 2.2.1 Spécificité de la détection dans différents milieux

La détection d'objets par LiDAR diffère sensiblement selon que l'on opère en milieu terrestre ou aquatique, et cette différence conditionne toute l'architecture du pipeline.

En **milieu terrestre**, tous les objets reposent sur le sol. Le LiDAR voit donc une surface continue qui les relie entre eux, et il devient impossible de les séparer en cherchant simplement des ruptures de distance. La solution habituelle consiste à calculer l'équation du plan du sol, puis à effacer tous les points qui lui appartiennent. Les objets se retrouvent alors isolés les uns des autres et peuvent être regroupés séparément. C'est le rôle de l'étape 4b 2.3, que nous avons utilisée lors de nos essais en environnement terrestre.

En **milieu aquatique**, il n'y a pas de sol. Le laser arrive sur la surface avec un angle très incliné : la plupart des rayons rebondissent au loin comme sur un miroir et ne reviennent jamais au capteur. L'eau ne renvoie donc que très peu de points.

Cette absence de sol constitue un avantage : la segmentation peut s'appliquer directement sur la matrice des distances  $\rho$  (étape 4a) 2.3.

### 2.2.2 Calibration et projection des données

En milieu marin, la plateforme d'acquisition est soumise en permanence aux mouvements des vagues, ce qui introduit des angles de roulis (*roll*) et de tangage (*pitch*) altérant l'alignement géométrique du nuage de points par rapport au plan d'eau. Pour compenser ce phénomène, une correction d'inclinaison est effectuée en exploitant les données de l'accéléromètre de la centrale inertielle (IMU) intégrée au capteur LiDAR.

L'IMU échantillonnant les données à une fréquence supérieure à celle du capteur LiDAR, plusieurs mesures inertielles sont acquises durant un unique balayage 3D. Afin de filtrer le bruit haute fréquence (comme les vibrations matérielles) et d'isoler précisément le vecteur de la gravité terrestre, une moyenne temporelle des composantes d'accélération ( $a_x, a_y, a_z$ ) est calculée sur la durée exacte de la trame LiDAR courante. À partir de ces composantes moyennées, les angles de roulis  $\phi$  et de tangage  $\theta$  mesurant l'inclinaison absolue de la plateforme sont estimés selon les relations trigonométriques 2.5. Les matrices de rotation élémentaires  $\mathbf{R}_x(\phi)$  et  $\mathbf{R}_y(\theta)$  sont explicitement définies par :

$$\mathbf{R}_x(\phi) = \begin{bmatrix} 1 & 0 & 0 \\ 0 & \cos \phi & -\sin \phi \\ 0 & \sin \phi & \cos \phi \end{bmatrix} \quad \text{et} \quad \mathbf{R}_y(\theta) = \begin{bmatrix} \cos \theta & 0 & \sin \theta \\ 0 & 1 & 0 \\ -\sin \theta & 0 & \cos \theta \end{bmatrix} \quad (2.7)$$

La matrice de rotation globale compensatoire est obtenue par la transposée du produit de ces rotations :

$$\mathbf{R}_{correction} = (\mathbf{R}_y(\theta) \cdot \mathbf{R}_x(\phi))^T \quad (2.8)$$

Cependant, une rotation s'effectue toujours mathématiquement autour de l'origine du repère  $(0, 0, 0)$ . Or, au sein du boîtier de l'Ouster OS1, le centre optique d'émission du LiDAR et le centre de la centrale inertielle ne sont pas confondus. Appliquer  $\mathbf{R}_{correction}$  directement à l'origine du nuage introduirait donc une erreur géométrique : la rotation doit s'effectuer autour du centre de l'IMU, puisque c'est ce composant qui a mesuré l'inclinaison. Ce changement de pivot s'exprime par un vecteur de translation  $\mathbf{d}$  séparant les deux composants. Selon le manuel constructeur de l'Ouster OS1 [11], les vecteurs de translation du LiDAR et de l'IMU vers le repère central du capteur (*Sensor Coordinate Frame*) valent respectivement :

$$\mathbf{t}_{lidar} = \begin{bmatrix} 0 \\ 0 \\ 0,03618 \end{bmatrix} \quad \mathbf{t}_{imu} = \begin{bmatrix} 0,00625 \\ -0,01177 \\ 0,00764 \end{bmatrix} \quad (2.9)$$

Le vecteur de translation permettant de passer de l'origine optique du LiDAR au centre de l'IMU s'écrit donc  $\mathbf{d} = \mathbf{t}_{imu} - \mathbf{t}_{lidar}$ . La correction s'opère en coordonnées homogènes, à l'aide de matrices  $4 \times 4$  appliquées au vecteur de position étendu  $\tilde{\mathbf{p}} = [x, y, z, 1]^T$ , et se décompose en trois transformations rigides successives :

1. **Translation vers le centre de l'IMU** : le nuage de points subit une translation de  $-\mathbf{d}$  afin de placer l'origine du repère de calcul sur le pivot de rotation.

$$\mathbf{T}_1 = \begin{bmatrix} \mathbf{I}_{3 \times 3} & -\mathbf{d} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \quad (2.10)$$

2. **Compensation de l'inclinaison (Rotation)** : la matrice  $\mathbf{R}_{correction}$  est appliquée autour de ce nouveau pivot pour annuler le roulis et le tangage mesurés.

$$\mathbf{T}_2 = \begin{bmatrix} \mathbf{R}_{correction} & \mathbf{0}_{3 \times 1} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \quad (2.11)$$

3. **Retour au repère** : le nuage corrigé est translaté de  $+\mathbf{d}$  pour que l'origine redevienne le centre d'émission laser.

$$\mathbf{T}_3 = \begin{bmatrix} \mathbf{I}_{3 \times 3} & \mathbf{d} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \quad (2.12)$$


L'expression finale de la transformation globale  $\mathbf{T}_{globale}$ , qui relie un point brut  $\tilde{\mathbf{p}}_{brut}$  à sa position corrigée  $\tilde{\mathbf{p}}_{corrige}$ , est donnée par le produit matriciel de ces trois transformations :

$$\tilde{\mathbf{p}}_{corrige} = \underbrace{\mathbf{T}_3 \cdot \mathbf{T}_2 \cdot \mathbf{T}_1}_{\mathbf{T}_{globale}} \cdot \tilde{\mathbf{p}}_{brut} \quad \text{soit} \quad \mathbf{T}_{globale} = \begin{bmatrix} \mathbf{R}_{correction} & (\mathbf{I}_{3 \times 3} - \mathbf{R}_{correction}) \mathbf{d} \\ \mathbf{0}_{1 \times 3} & 1 \end{bmatrix} \quad (2.13)$$

Cette correction aligne l'axe  $Z$  du nuage de points sur la verticale du plan d'eau, à la précision des mesures inertielles près. Cet alignement conditionne la suite du traitement : la segmentation suppose en effet que la surface de l'eau soit sensiblement horizontale dans le repère de travail.

### 2.2.3 Extraction de la Région d'Intérêt (ROI)

Le capteur balaye  $360^\circ$ , mais seule la portion de plan d'eau située face à lui présente un intérêt pour le suivi. Une Région d'Intérêt (ROI) est donc définie afin de restreindre le traitement à ce champ de vision utile. Un fenêtrage sur l'azimut  $\theta$  conserve les 512 colonnes faisant face à l'eau, puis une délimitation dans le repère cartésien du capteur écarte les points situés hors des limites du plan d'eau observé. Le principe est illustré Figure 2.4.

FIGURE 2.4 – Extraction de la Région d’Intérêt (ROI) par fenêtrage de l’angle azimutal  $\theta$ .

## 2.2.4 Segmentation par distance radiale adaptative

La segmentation opère directement sur la matrice 2D des distances  $\rho$ , traitée comme une image de profondeur. Le principe consiste à détecter les discontinuités de profondeur entre cellules voisines, révélatrices d’un objet émergeant de la surface de l’eau. Comme pour les filtres classiques du traitement d’image, l’analyse porte sur le **voisinage** immédiat de chaque cellule  $(i, j)$  : le voisin horizontal  $(i, j - 1)$  et le voisin vertical  $(i - 1, j)$ . Pour chaque paire, le saut de distance est évalué, soit  $s = |\rho(i, j) - \rho(i, j - 1)|$  dans la direction horizontale. Une frontière d’objet est marquée lorsque ce saut dépasse un seuil adaptatif  $\tau$ , qui évolue selon l’historique des variations locales afin de s’affranchir du bruit généré par les vagues :

$$\tau = \max(\epsilon_{Ouster}, 1,5 \times \mu_{sautes}) \quad (2.14)$$

où  $\epsilon_{Ouster} = 0,03$  m est la précision intrinsèque du capteur, plancher sous lequel il serait illusoire de descendre, et  $\mu_{sautes}$  la moyenne glissante des sauts observés sur la surface continue courante. Le coefficient multiplicatif a été fixé empiriquement : une valeur plus faible laisse passer de nombreuses frontières parasites dues à l’agitation de surface, tandis qu’une valeur plus élevée fait disparaître les objets les moins émergés. La valeur 1,5 constitue le meilleur compromis observé sur nos acquisitions, sans prétendre à une optimalité générale. En l’absence d’historique au début d’un balayage, un seuil initial fixe de 0,05 m est appliqué.

Le masque de frontières obtenu est ensuite combiné au masque des points valides. Une opération morphologique de fermeture, appliquée sur un voisinage  $3 \times 3$ , comble les trous laissés par les zones de faible réflectivité, fréquentes sur les matériaux plastiques partiellement immergés. Les cellules restantes sont enfin regroupées en régions par un algorithme d’**étiquetage en composantes connexes**, méthode standard d’analyse d’image disponible dans l’*Image Processing Toolbox* [9].




FIGURE 2.5 – Détection des discontinuités radiales sur la matrice LiDAR.

Nous retenons la **8-connexité** : deux cellules appartiennent à une même région si elles sont adjacentes dans l'un des huit voisinages, soit les quatre directions cardinales et les quatre diagonales. Ce choix est dicté par la nature des données : les objets lointains ou peu réfléchissants renvoient un signal dispersé, et une 4-connexité fragmenterait un même déchet en plusieurs sous-régions. Sur nos acquisitions, la 8-connexité préserve mieux l'intégrité spatiale des cibles, sans constituer pour autant la seule stratégie envisageable.

### 2.2.5 Extraction des boîtes englobantes des objets

Chaque région identifiée lors de l'étiquetage est ensuite ramenée dans le repère cartésien du capteur. Les régions de très faible étendue sont écartées : lorsqu'une région ne réunit qu'une poignée de points sans réelle continuité spatiale entre eux, elle traduit le plus souvent un retour parasite lié à l'agitation de surface ou au bruit du capteur, plutôt qu'un objet réel. Le seuil retenu est volontairement bas, afin de ne pas éliminer les cibles éloignées qui renvoient naturellement moins de points. Pour chaque objet validé  $k$ , les dimensions de la boîte englobante (*Axis-Aligned Bounding Box* — AABB) sont calculées en cherchant les valeurs maximales et minimales de l'ensemble de ses points sur les axes  $X$ ,  $Y$  et  $Z$ . Si l'on note  $l$  la largeur,  $p$  la profondeur et  $h$  la hauteur, on obtient mathématiquement :

$$\begin{cases} l = \max(X_k) - \min(X_k) \\ p = \max(Y_k) - \min(Y_k) \\ h = \max(Z_k) - \min(Z_k) \end{cases} \quad (2.15)$$

Le centre de cette boîte, noté  $c_k = (x_c, y_c, z_c)^T$ , est obtenu en ajoutant la demi-largeur, la demi-profondeur et la demi-hauteur aux coordonnées minimales :

$$c_k = \begin{pmatrix} x_c \\ y_c \\ z_c \end{pmatrix} = \begin{pmatrix} \min(X_k) + \frac{l}{2} \\ \min(Y_k) + \frac{p}{2} \\ \min(Z_k) + \frac{h}{2} \end{pmatrix} \quad (2.16)$$

Il s'agit du centre géométrique de la boîte englobante, et non du centre de gravité du nuage de points : le LiDAR n'éclairant que la face visible de l'objet, ces deux points ne coïncident pas. Ce centre constitue la mesure transmise aux algorithmes de suivi. Il ne s'agit donc pas d'une position exacte, mais d'une estimation entachée du bruit du capteur et de l'occultation partielle de la cible, incertitude dont les filtres présentés en Section 2.3 devront tenir compte.

### Applications terrestres : suppression du plan du sol

Cette étape ne concerne que le milieu terrestre. Comme expliqué en Section 2.2.1, aucun plan d'eau n'est estimé en milieu aquatique : la surface ne renvoie pas assez de points pour qu'un tel plan ait un sens, et l'absence de sol est précisément ce qui rend la segmentation radiale possible. L'étape 4b a servi uniquement à valider l'extraction des boîtes englobantes en environnement structuré, où les objets reposent sur un plan solide qui les relie entre eux. Notre fonction d'extraction opère directement sur la matrice tensorielle en quatre phases :

1. **Détection par histogramme 1D** : Pour éviter d'inclure le plafond (en intérieur) ou la cime des arbres (en extérieur), l'algorithme restreint son analyse à la moitié basse du nuage de points. Un histogramme des altitudes  $Z$  est généré avec 100 intervalles. Le pic majeur de cet histogramme correspond logiquement à la surface plane dominante : le sol.
2. **Estimation du plan par Moindres Carrés** : Les points appartenant à ce pic d'altitude sont isolés. L'équation cartésienne du plan du sol ( $Z = AX + BY + D$ ) est alors calculée de manière optimale via la méthode des moindres carrés (résolution matricielle).
3. **Raffinement strict** : Pour obtenir une précision maximale, une seconde passe est effectuée en ne conservant que les points situés à moins de 5 mm du premier plan estimé. Les paramètres mathématiques  $(A, B, D)$  sont recalculés. La valeur absolue  $|D|$  nous donne par ailleurs la hauteur géométrique exacte du capteur LiDAR par rapport au sol.
4. **Filtrage de la matrice LiDAR** : Enfin, l'algorithme parcourt l'intégralité de la grille 3D d'origine. Tout point dont la hauteur relative par rapport au plan calculé est inférieure à une tolérance stricte de 1 cm (soit  $Z_{brut} - (AX + BY + D) \leq 0,01$  m) est considéré comme appartenant au sol. Ses coordonnées sont remplacées par des valeurs nulles (NaN).




FIGURE 2.6 – Détection 1D du sol par extraction du pic majeur de l’histogramme des altitudes  $Z$ .

Cette méthode conserve l’organisation tensorielle du nuage (*Organized Point Cloud*) tout en effaçant numériquement le plancher. Les objets terrestres (seaux, cartons, piétons) se retrouvent alors isolés spatialement, et peuvent être traités par l’algorithme d’extraction des boîtes englobantes 3D. Afin de valider la robustesse de l’algorithme de segmentation et d’extraction des boîtes avant son déploiement en milieu marin, un test préliminaire a été réalisé en environnement structuré (couloir du laboratoire). Comme l’illustre la Figure 2.8, le système parvient à segmenter correctement les objets isolés et à en extraire les boîtes englobantes (en vert).



FIGURE 2.7 – Mise en situation réelle (environnement de test structuré).




FIGURE 2.8 – Résultat de l’extraction des boîtes englobantes 3D.

Afin de pousser cette validation terrestre plus loin et d'éprouver l'algorithme face à un environnement plus complexe, une seconde série de tests a été réalisée en extérieur. Comme le montre la Figure 2.9, plusieurs objets de tailles différentes ont été disposés sur une allée goudronnée.

La Figure 2.10 illustre le résultat tridimensionnel du traitement : après l'étape de suppression du plan du sol, le système parvient à segmenter simultanément les multiples cibles et à en extraire les boîtes englobantes (encadrés verts). On remarque également que le capteur LiDAR restitue fidèlement la géométrie de l'arrière-plan (arbres, poteau d'éclairage). Dans notre pipeline maritime final, ces éléments parasites lointains sont naturellement ignorés grâce à la délimitation spatiale de la Région d'Intérêt (ROI).




FIGURE 2.9 – Mise en situation réelle en extérieur (multi-objets sur une allée).




FIGURE 2.10 – Résultat LiDAR 3D : boîtes englobantes et éléments de l'environnement.

## 2.2.6 Synthèse algorithmique : Le détecteur complet

L'algorithme 1 synthétise notre pipeline de détection maritime : il prend en entrée la matrice des distances et retourne, pour chaque objet détecté, le centre de sa boîte englobante ainsi que ses dimensions.

---

### Algorithme 1 Segmentation et extraction des boîtes englobantes

---

**Entrées :** Matrice  $\rho_{sans\_sol}$  ( $H \times W$ ), Nuage cartésien  $PtCloud$

**Sorties :** Liste des centres  $C$ , Liste des boîtes  $B$

```

1:  $F_{horiz} \leftarrow \text{Faux}(H, W - 1)$ ,  $F_{vert} \leftarrow \text{Faux}(H - 1, W)$ 
▷ 1. Détection des sauts (Balayages H et V)

2: pour chaque point adjacent  $p_1, p_2$  (horizontalement puis verticalement) faire
3:    $saut \leftarrow |\rho(p_2) - \rho(p_1)|$ 
4:   si  $saut > \tau$  alors ▷  $\tau$  mis à jour dynamiquement
5:     Marquer la frontière ( $F_{horiz}$  ou  $F_{vert}$ ) à Vrai
6:   fin si
7: fin pour
▷ 2. Traitement d'image 2D

8:  $Image_{obj} \leftarrow (\rho_{sans\_sol} > 0)$  découpée par les frontières  $F_{horiz}$  et  $F_{vert}$ 
9:  $Image_{obj} \leftarrow \text{Fermeture\_Morphologique}(Image_{obj}, \text{fenêtre } 3 \times 3)$ 
10:  $Labels, N_{reg} \leftarrow \text{Etiquetage\_Composantes\_Connexes}(Image_{obj}, 8\text{-connexité})$ 
▷ 3. Extraction cartésienne 3D

11:  $C \leftarrow []$ ,  $B \leftarrow []$ 
12: pour  $k = 1$  à  $N_{reg}$  faire
13:    $(X_k, Y_k, Z_k) \leftarrow \text{Extraire les coordonnées du label } k \text{ depuis } PtCloud$ 
14:   si  $\text{Nombre\_de\_points}(X_k) \geq 5$  alors ▷ Filtre anti-bruit
15:      $l, p, h \leftarrow \max(X_k) - \min(X_k), \max(Y_k) - \min(Y_k), \max(Z_k) - \min(Z_k)$ 
16:      $(x_c, y_c, z_c) \leftarrow (\min(X_k) + l/2, \min(Y_k) + p/2, \min(Z_k) + h/2)$ 
17:     Ajouter  $(x_c, y_c, z_c)$  à  $C$  et  $(x_c, y_c, z_c, l, p, h)$  à  $B$ 
18:   fin si
19: fin pour
20: retourner  $C, B$ 

```

---

## 2.3 Suivi multi-objets (MOT)

Le module de détection fournit, à chaque trame, une liste de centres d'objets, sans lien d'une trame à l'autre. Le suivi multi-objets a pour rôle de relier ces détections successives en trajectoires cohérentes, d'attribuer un identifiant stable à chaque cible et d'estimer sa cinématique, y compris lorsqu'une observation vient à manquer. Le problème de suivi est modélisé selon un modèle cinématique à accélération constante. Le vecteur d'état est défini par  $X_k = [x, y, z, v_x, v_y, v_z, a_x, a_y, a_z]^T$  où  $(x, y, z)$  est la position du déchet flottant dans le repère monde,  $(v_x, v_y, v_z)$  les composantes de sa vitesse et  $(a_x, a_y, a_z)$  celles de son accélération. Quatre algorithmes d'estimation ont été développés et évalués. L'implémentation de ces quatre filtres constitue une demande explicite du cahier des charges du stage : l'objectif n'est pas d'optimiser empiriquement les paramètres d'un estima-

teur unique, mais de confronter, sur les mêmes données et avec la même chaîne de détection, les approches probabilistes et ensemblistes.

### 2.3.1 Principe d'association par Distance de Mahalanobis

Dans tout système de suivi multicible, la détection ne peut être parfaite : elle manque des cibles et en produit de fausses. En milieu marin, l'agitation de la surface accentue ce phénomène. Il est donc impératif d'évaluer si une nouvelle mesure brute correspond physiquement à la cinématique de l'objet suivi. Pour ce faire, nous employons un critère statistique fondé sur la distance de Mahalanobis  $d_M$ . Cette méthode définit une *région de validation* autour de la position prédite de l'objet. La distance est pondérée par la matrice de covariance de l'innovation  $S$ , qui représente la zone d'incertitude théorique du système :

$$d_M = \sqrt{(Y_k - \hat{Y}_{k|k-1})^T S^{-1} (Y_k - \hat{Y}_{k|k-1})} \quad (2.17)$$

Une mesure est considérée comme candidate si elle vérifie  $d_M < 3,5$ . Ce seuil n'est pas arbitraire : il correspond à un niveau de confiance de plus de 99 % pour une distribution à 3 degrés de liberté, selon la loi du  $\chi^2$ . Il définit une région de validation, ellipsoïde dans lequel la cible se trouve très probablement. Toute mesure située au-delà est attribuée au bruit de vague et ignorée. Les deux mécanismes de l'association sont complémentaires. La distance de Mahalanobis est normalisée par l'incertitude  $S$  : la région de validation s'élargit lorsque le filtre est incertain et se resserre lorsqu'il est confiant, ce qu'un seuil en mètres ne permettrait pas. Elle sert aussi de critère de rejet, sans lequel une piste s'associerait toujours à la détection la plus proche, même s'il s'agit d'un écho de vague. Le plus proche voisin n'intervient qu'ensuite, lorsque plusieurs mesures franchissent la région d'une même cible. Les pistes sont parcourues de la plus ancienne à la plus récente ; chacune retient la détection disponible qui minimise sa distance, puis cette détection devient indisponible pour les suivantes. L'association reste ainsi unique, et la priorité revient aux pistes les mieux établies.

**Région de validation (Ellipsoïde de confiance à  $3,5\sigma$ )**




FIGURE 2.11 – Principe d'association de données par la distance de Mahalanobis  $d_M$ .

Bien que ce principe de validation spatiale soit commun à l'ensemble de notre architecture, la modélisation mathématique de l'incertitude géométrique (la matrice de covariance de l'innovation  $S$ ) diffère fondamentalement selon la nature du filtre employé. Le Tableau 2.1 synthétise ces différences :

| Modèle d'estimation        | Covariance de l'innovation ( $S$ )  | Approche mathématique                           |
|----------------------------|-------------------------------------|-------------------------------------------------|
| Filtre de Kalman           | $S = CP_{k k-1}C^T + R$             | Propagation gaussienne                          |
| Kalman Ensembliste (UBIKF) | $S_k = CP_{k k-1}^+C^T + R$         | Borne supérieure garantie                       |
| Filtre Particulaire        | $S = P_{particules} + R$            | Dispersion spatiale des particules              |
| Box Particle Filter (BPF)  | $S_k = P_{nuage\_boites} + R_{cov}$ | Dispersion des centres + taille des intervalles |

TABLE 2.1 – Méthodes d'évaluation de l'incertitude géométrique  $S$  pour l'association de données.

Afin de répondre précisément aux défis du milieu marin, il convient de détailler le calcul de cette matrice d'incertitude  $S$  selon la famille de filtres :

- **Pour les méthodes de Kalman (Classique et UBIKF) :** La matrice  $S$  se déduit directement des équations du filtre. Elle additionne l'incertitude du modèle mathématique projetée dans l'espace de mesure ( $CP C^T$ ) avec la matrice de covariance du bruit du capteur LiDAR ( $R$ ). Dans le cas de l'UBIKF, la matrice  $P^+$  garantit mathématiquement que cette incertitude géométrique englobe toutes les erreurs possibles, sans jamais sous-estimer la zone de recherche.
- **Pour le Filtre Particulaire classique :** L'incertitude  $P_{particules}$  n'est plus calculée par une formule fermée, mais de manière empirique. Elle correspond à la covariance statistique (la mesure de l'éparpillement spatial) des coordonnées 3D de l'ensemble du nuage de particules. On y ajoute ensuite l'erreur de mesure du capteur  $R$ .
- **Pour le Box Particle Filter (BPF) :** Le calcul de la matrice  $P_{nuage\_boites}$  est une approche hybride intégrant deux composantes physiques distinctes de la boîte :
  1. **La dispersion des trajectoires :** La covariance classique calculée uniquement sur la position des centres géométriques des différentes boîtes.
  2. **Le volume d'incertitude intrinsèque :** Une matrice diagonale contenant la moyenne des demi-largeurs (les rayons) de toutes les boîtes, élevée au carré.

Cette formulation mathématique est cruciale : même si toutes les boîtes convergent vers un centre unique (dispersion nulle), la matrice  $S_k$  conserve une taille cohérente avec l'incer-

titude réellement portée par les boîtes. On y ajoute enfin une matrice  $R_{cov}$  représentant la tolérance d'association géométrique du capteur.

### Justification du choix des modèles d'estimation :

L'implémentation et la comparaison de ces quatre architectures répondent à une démarche scientifique progressive, visant à démontrer l'intérêt de l'analyse par intervalles :

- **Le Filtre de Kalman classique** : Il sert de modèle de référence (*baseline*). Très rapide, il est optimal lorsque le bruit est blanc et gaussien. Or l'agitation de surface produit un bruit borné en amplitude et corrélé dans le temps, si bien que cette hypothèse n'est pas vérifiée ici.
- **Le Filtre Particulaire classique** : Il ne suppose plus que la densité a posteriori de l'état reste gaussienne, même si le bruit de modèle et la vraisemblance le demeurent. Cependant, lors d'un masquage prolongé, aucune mesure ne vient renouveler les poids : le rééchantillonnage duplique les mêmes particules et la diversité du nuage s'appauvrit, jusqu'à l'effondrement de sa variance.
- **Le Filtre de Kalman Ensembliste (UBIKF)** : Il introduit l'approche par intervalles dans le modèle de Kalman. Il ajoute à l'hypothèse probabiliste une incertitude bornée sur les paramètres du modèle. La borne supérieure garantit alors que la cible reste dans la zone estimée. Cette garantie a un coût, l'estimation étant volontairement pessimiste : le filtre n'est donc pas préférable en toute circonstance, mais il l'est ici, où le bruit est mal caractérisé statistiquement tout en restant physiquement borné.
- **Le Box Particle Filter (BPF)** : Il représente l'aboutissement de cette architecture. En combinant la souplesse du filtrage particulaire avec la rigueur géométrique des boîtes d'intervalles, il vise à maintenir une estimation robuste de la trajectoire même lors d'occlusions prolongées, chaque boîte couvrant un volume de l'espace d'état au lieu d'un point unique, un nombre réduit d'entités suffit à explorer ce même espace, comme l'ont montré Abdallah *et al.* [7].

## 2.3.2 Filtre de Kalman

Le filtre de Kalman repose sur un modèle cinématique linéaire et sur l'hypothèse que les bruits de mesure et de modèle suivent des lois normales (gaussiennes). Le vecteur d'état du système modélisant un déchet flottant est défini par sa position cartésienne 3D et sa vitesse tridimensionnelle :

$$X_k = [x, y, z, v_x, v_y, v_z, a_x, a_y, a_z]^T.$$

L'évolution dynamique de l'objet et les observations du capteur sont régies par le système d'équations d'état discret suivant :

$$\begin{cases} X_k = AX_{k-1} + w_k \\ Y_k = CX_k + v_k \end{cases} \quad (2.18)$$

où  $w_k$  et  $v_k$  représentent respectivement le bruit de procédé (modèle) et le bruit de mesure.

Dans le cadre d'un modèle cinématique à accélération constante, paramétré par l'intervalle de temps  $\Delta t$  entre deux trames LiDAR, la matrice de transition  $A$  et la matrice d'observation  $C$  (le capteur ne mesurant que les positions) sont définies par :

$$A = \begin{pmatrix} I_3 & \Delta t I_3 & \frac{1}{2} \Delta t^2 I_3 \\ 0_{3 \times 3} & I_3 & \Delta t I_3 \\ 0_{3 \times 3} & 0_{3 \times 3} & I_3 \end{pmatrix}, \quad C = \begin{pmatrix} I_3 & 0_{3 \times 6} \end{pmatrix} \quad (2.19)$$

où  $I_3$  est la matrice identité de dimension  $3 \times 3$ . Les incertitudes du système sont modélisées par la matrice de covariance du bruit de procédé  $Q$  et la matrice de covariance du bruit de mesure  $R$ , définies empiriquement pour tolérer la dynamique stochastique du milieu aquatique.

L'algorithme opère en trois phases distinctes pour chaque trame :

### 1. Phase de prédiction :

Le filtre projette l'état précédent et son incertitude vers l'instant courant. L'état futur projeté  $X_{k|k-1}$  et la matrice de covariance de l'erreur de prédiction  $P_{k|k-1}$  sont estimés selon les équations suivantes :

$$X_{k|k-1} = AX_{k-1|k-1} \quad (2.20)$$

$$P_{k|k-1} = AP_{k-1|k-1}A^T + Q \quad (2.21)$$


### 2. Association des mesures :

La matrice de covariance de l'innovation  $S$  est calculée analytiquement par :

$$S = CP_{k|k-1}C^T + R \quad (2.22)$$

L'association s'effectue par le calcul de la distance de Mahalanobis  $d_M$ , et non par une simple distance euclidienne. Les deux ne coïncident pas :  $d_M$  pondère l'écart par la matrice  $S$ , de sorte qu'une mesure éloignée dans une direction où le filtre est très incertain peut être plus crédible qu'une me-

sure proche dans une direction où il est confiant. C'est cette normalisation qui permet à la région de validation de s'adapter à l'état du filtre. Comme l'illustre la Figure 2.12, en cas de rapprochement de cibles ou d'occlusion partielle, une même mesure peut être valide pour deux pistes. La règle décrite en Section 2.3.1 s'applique alors : la mesure revient à la piste la plus ancienne parmi celles qui la retiennent. L'autre objet, privé de mesure, est considéré comme momentanément caché.



**Résolution du conflit :**

La mesure appartient aux deux régions de validation ( $d_M < 3,5$ ). L'Objet 1, piste la plus ancienne, est traité en premier : il se voit attribuer la mesure, qui devient alors indisponible. L'Objet 2 ne reçoit aucune observation et passe en mode "occlusion".

FIGURE 2.12 – Traitement par distance de Mahalanobis lorsqu'un objet masque un autre.

### 3. Phase de correction et gestion du cycle de vie (occlusions et sorties) :

Lorsqu'une détection valide est associée à la piste, l'état et sa covariance sont mis à jour grâce au gain de Kalman  $K$ , qui arbitre la confiance entre le modèle mathématique et la mesure associée :

$$K = P_{k|k-1} C^T S^{-1} \quad (2.23)$$

$$X_{k|k} = X_{k|k-1} + K(Y_k - C X_{k|k-1}) \quad (2.24)$$

$$P_{k|k} = (I_9 - KC)P_{k|k-1} \quad (2.25)$$

Cependant, en milieu marin et terrestre, il arrive fréquemment qu'aucune mesure ne puisse être associée à un objet. Cela se produit dans trois cas bien précis : **un déchet est noyé sous une vague, il est physiquement et totalement caché par un autre déchet plus gros, ou l'objet sort définitivement de la zone d'observation (ROI).**

Dans ces situations, le filtre passe en mode de prédiction pure. L'étape de correction est ignorée ( $X_{k|k} = X_{k|k-1}$ ) et l'erreur d'estimation ( $P_{k|k}$ ) croît mécaniquement à chaque itération, traduisant la perte progressive de confiance dans la position estimée. La gestion du cycle de vie des pistes s'appuie sur cette situation : chaque piste conserve en mémoire le nombre de trames consécutives

sans observation. Au-delà de dix trames, la piste est supprimée. Ce mécanisme évite de maintenir indéfiniment des pistes correspondant à des objets sortis de la ROI ou ayant coulé.

### 2.3.3 Filtre de Kalman ensembliste (UBIKF)

#### Introduction aux méthodes par intervalles

Avant de détailler l'algorithme d'estimation, il est nécessaire de définir les concepts fondamentaux de l'analyse ensembliste. Contrairement à l'arithmétique stochastique classique qui manipule des nombres réels, cette approche manipule des intervalles fermés  $[x] = [\underline{x}, \bar{x}]$ . En dimension multiple, un vecteur composé d'intervalles forme une boîte (ou box) délimitant strictement une zone de l'espace. De la même manière, les incertitudes bornées sur les paramètres d'un modèle dynamique sont représentées par des matrices d'intervalles.

#### Architecture du filtre UBIKF

Pour faire face aux bruits complexes (non blancs et biaisés) générés par l'agitation de la surface de l'eau (environnement complexe et incertain), une approche ensembliste a été développée : le filtre UBIKF (*Upper Bound Interval Kalman Filter*). Cette méthode s'appuie sur deux travaux de recherche majeurs : les équations de correction ensemblistes par propagation de contraintes de Xiong et al. (2013) et l'optimisation de la matrice de covariance de Tran et al. (2021) [5] & [6].

L'originalité de ce filtre repose sur l'utilisation hybride d'intervalles et de matrices réelles afin d'éviter la divergence infinie des calculs (un phénomène connu sous le nom de *wrapping effect*). Contrairement à la théorie générale où toutes les matrices peuvent être incertaines, notre modèle cinématique repose sur un temps d'échantillonnage  $\Delta t$  parfaitement connu. Ainsi, les matrices de transition  $A$  et d'observation  $C$  restent des matrices réelles exactes.

L'incertitude globale du système est alors modélisée par deux concepts distincts :

- $[V_{modele}]$  (**Boîte d'intervalles**) : modélise les perturbations physiques externes maximales (le mouvement imprévisible des vagues) sous forme d'une boîte d'intervalles tolérant des variations précises de position, vitesse et accélération à chaque itération.
- $Q$  et  $R$  (**Covariances réelles**) : sont des matrices réelles classiques utilisées exclusivement pour propager l'erreur d'estimation du filtre. Selon la théorie de Tran et al. (2021) [6], cela permet de calculer une matrice  $P_k^+$  qui représente une "borne supérieure" de l'erreur, sans subir l'explosion numérique inhérente au calcul par intervalles.

L'algorithme se déroule en quatre étapes :

### 1. Phase de prédiction :

L'état futur est prédit sous forme de boîte en appliquant la matrice exacte  $A$  et en y ajoutant l'incertitude physique  $[V_{modele}]$ . En parallèle, la borne supérieure de covariance  $P_{k|k-1}^+$  est propagée de manière classique avec le bruit  $Q$  :

$$[X_{k|k-1}] = A[X_{k-1|k-1}] + [V_{modele}] \quad (2.26)$$

$$P_{k|k-1}^+ = AP_{k-1|k-1}^+ A^T + Q \quad (2.27)$$

### 2. Association de données :

L'algorithme extrait le centre géométrique exact de la boîte prédite. L'incertitude théorique est garantie par la borne supérieure  $S_k = CP_{k|k-1}^+ C^T + R$ . Si la distance de Mahalanobis associée respecte la région de validation ( $d_M < 3,5$ ), l'association est confirmée. La mesure LiDAR brute est alors transformée en une boîte d'intervalle stricte  $[Y_k]$  encadrant l'erreur maximale du capteur.

### 3. Phase de correction hybride :

La phase de correction repose sur le formalisme mathématique développé par Xiong et al. (2013) [5]. Dans un premier temps, le gain de Kalman optimal  $K$  est évalué à partir de la matrice de covariance réelle  $P_{k|k-1}^+$  augmenté de sa mise en forme. L'état du système est ensuite mis à jour en appliquant l'algèbre des intervalles (propagation de contraintes forward-backward) :

$$K = P_{k|k-1}^+ C^T S_k^{-1} \quad (2.28)$$

$$[a_1] = [C][X_{k|k-1}] \quad (2.29)$$

$$[a_2] = [Y_k] - [a_1] \quad (2.30)$$

$$[X_{k|k}^*] = [X_{k|k-1}] + K[a_2] \quad (2.31)$$

La variable  $[X_{k|k}^*]$  représente la boîte d'état a posteriori brute. Il s'agit de l'estimation purement mathématique calculée par la théorie de Kalman, juste avant de lui appliquer les lois physiques de l'environnement pour la contracter.

Parallèlement, la matrice de covariance est mise à jour pour garantir la borne supérieure de l'incertitude, selon l'approche de Tran et al. (2021) [6] :

$$P_{k|k}^+ = (I_9 - KC)P_{k|k-1}^+ \quad (2.32)$$

#### 4. Optimisation par propagation de contraintes :

Le filtre utilise le formalisme de propagation de contraintes (CSP) de Xiong et al. (2013) [5] :

- **Contrainte spatiale absolue** : Une intersection mathématique stricte est réalisée entre la position corrigée de la boîte d'état  $[X_{k|k}^*]$  et la boîte de mesure LiDAR réelle  $[Y_k]$ . Toute estimation mathématique débordant de la réalité physique mesurée par le capteur est instantanément coupée. (*Nota : si l'intersection s'avère vide suite à une aberration de mesure, l'algorithme sécurise le suivi en adoptant directement la boîte de mesure LiDAR*).
- **Contrainte cinématique backward** : Une vitesse observée est recalculée "à l'envers" en divisant le déplacement géométrique réel (entre la nouvelle position spatiale contrainte et la position de la trame précédente) par le temps  $\Delta t$ . Parallèlement, l'incertitude de la vitesse issue de  $[X_{k|k}^*]$  est mathématiquement bornée à  $1,5\sigma$  (dédit des éléments diagonaux de  $P_{k|k}^+$ ). L'intersection de ces deux grandeurs permet de lisser l'estimation et de bloquer les accélérations physiquement impossibles.

---

**Algorithme 2** Contraction de la boîte d'état a posteriori par propagation de contraintes (Xiong et al., 2013 ; Tran et al., 2021)

---

**Entrées :**  $[X_{k|k}^*]$  (boîte a posteriori brute),  $[Y_k]$  (boîte de mesure LiDAR),  $P_{k|k}^+$  (covariance supérieure),  $X_{k-1|k-1}$  (état corrigé précédent),  $\Delta t$

**Sorties :**  $[X_{k|k}]$  (boîte d'état contractée) // *Contrainte spatiale absolue*

```

1:  $[P_{k|k}^*] \leftarrow$  composante position extraite de  $[X_{k|k}^*]$ 
2: si  $[P_{k|k}^*] \cap [Y_k] \neq \emptyset$  alors
3:    $[P_{k|k}] \leftarrow [P_{k|k}^*] \cap [Y_k]$  ▷ intersection stricte
4: sinon
5:    $[P_{k|k}] \leftarrow [Y_k]$  ▷ sécurisation en cas d'aberration de mesure
6: fin si // Contrainte cinématique backward
7:  $[V_{backward}] \leftarrow \frac{[P_{k|k}] - P_{k-1|k-1}}{\Delta t}$  ▷ vitesse recalculée à l'envers
8:  $\sigma_V \leftarrow \sqrt{\text{diag}(P_{k|k}^+)_{\text{vitesse}}}$ 
9:  $[V_{k|k}] \leftarrow [V_{k|k}^*] \cap [[V_{backward}] - 1,5\sigma_V, [V_{backward}] + 1,5\sigma_V]$ 
10:  $[X_{k|k}] \leftarrow ([P_{k|k}], [V_{k|k}])$ 
11: retourner  $[X_{k|k}]$ 

```

---

#### 2.3.4 Filtre particulaire (Monte-Carlo)

Le filtre particulaire approche la densité de probabilité de l'état cinématique non pas par une fonction mathématique stricte, mais par une méthode de Monte-Carlo utilisant un ensemble de  $N$  par-

ticules discrètes pondérées. Chaque particule  $i$  représente une hypothèse d'état

$X^{(i)} = [x, y, z, v_x, v_y, v_z, a_x, a_y, a_z]^T$  et possède un poids  $w^{(i)}$  reflétant sa probabilité. L'algorithme se déroule en quatre étapes fondamentales pour chaque itération :

### 1. Phase de prédiction :

Contrairement au filtre de Kalman qui propage une matrice de covariance, le filtre particulaire déplace physiquement chaque particule selon le modèle cinématique à accélération constante (matrice  $A$ ). Pour simuler l'incertitude du modèle marin (bruit de procédé), un bruit aléatoire gaussien est généré via la décomposition de Cholesky de la matrice  $Q$  et ajouté à chaque particule :

$$X_{k|k-1}^{(i)} = AX_{k-1|k-1}^{(i)} + \mathcal{N}(0, Q) \quad (2.33)$$

L'état global estimé du système est alors défini comme la moyenne pondérée de toutes les particules prédites.

### 2. Association de données :

La matrice d'incertitude géométrique de la prédiction  $P_{nuage}$  est calculée empiriquement via la dispersion (covariance) des coordonnées 3D du nuage de particules. L'incertitude totale d'association intègre la précision du capteur :  $S = P_{nuage} + R$ . L'association est ensuite validée par la distance de Mahalanobis ( $d_M < 3,5$ ) entre le centre prédit et la détection LiDAR.

### 3. Phase de correction (Mise à jour des poids) :

Lorsqu'une mesure  $Y_k$  est validée, l'innovation géométrique est calculée individuellement pour chaque particule. Le poids de chaque particule est alors actualisé en évaluant sa vraisemblance via une fonction gaussienne basée sur l'erreur du capteur  $R$  :

$$\text{innov}^{(i)} = Y_k - CX_{k|k-1}^{(i)} \quad \text{avec } 1 \leq i \leq N$$

$$w_k^{(i)} = w_{k-1}^{(i)} \times \exp \left( -\frac{1}{2} \text{innov}^{(i)T} R^{-1} \text{innov}^{(i)} \right)$$

Une constante de sécurité ( $10^{-15}$ ) est ajoutée pour éviter les probabilités strictement nulles, puis l'ensemble des poids est normalisé pour que leur somme soit égale à 1.

### 4. Rééchantillonnage (Resampling) et Occlusions :

Au fil des itérations, un phénomène de dégénérescence survient : le poids se concentre sur un très petit nombre de particules, les autres ne contribuant plus de façon significative à l'estimation. Pour contrer cela, le nombre de particules effectives est calculé :  $N_{eff} = 1 / \sum (w_k^{(i)})^2$ . Cette quantité

s'interprète comme le nombre de particules contribuant réellement à l'estimation : elle vaut  $N$  lorsque les poids sont uniformes et tend vers 1 lorsqu'une seule particule domine. Le rééchantillonnage est déclenché lorsque  $N_{eff}$  passe sous  $N/2$ , seuil couramment retenu dans la littérature [4] : il correspond au moment où la moitié de l'effectif est devenue inopérante, et constitue un compromis entre rééchantillonner trop souvent, ce qui appauvrit la diversité du nuage, et trop tard, ce qui laisse la dégénérescence s'installer. Les particules aux poids négligeables sont éliminées, tandis que les particules fortement probables sont dupliquées, et tous les poids sont réinitialisés à  $1/N$ .

En cas d'occlusion, aucune mesure n'est disponible : les poids ne peuvent donc pas être actualisés, et la correction n'a pas lieu d'être. Le rééchantillonnage est également suspendu, car il dupliquerait les particules les mieux notées à la dernière observation reçue, figeant le nuage sur une information périmée au lieu de le laisser explorer les positions devenues possibles. Le filtre se contente de la phase de prédiction, augmentant naturellement la dispersion du nuage de particules jusqu'à la réapparition de l'objet ou la suppression de la piste.

### 2.3.5 Filtre particulaire par intervalles (Box Particle Filter)

Le filtre particulaire par boîtes (BPF) constitue une approche hybride avancée qui combine la flexibilité séquentielle des méthodes de Monte-Carlo avec la rigueur mathématique de l'analyse par intervalles. Contrairement au filtre particulaire classique où chaque particule est un point, chaque entité est ici une boîte contenant une infinité d'états cinématiques possibles. Cette méthode permet d'explorer efficacement l'espace d'état avec un nombre d'entités nettement inférieur à celui d'un filtre particulaire classique : chaque boîte couvrant un volume de l'espace d'état au lieu d'un point unique, une dizaine de boîtes suffit là où plusieurs centaines de particules seraient nécessaires [7]. L'algorithme se décline en quatre étapes principales :

#### 1. Phase de prédiction des boîtes :

Chaque boîte  $b$  est propagée dans le temps en utilisant la matrice de transition sous forme d'intervalles  $A_{int}$  et une boîte d'incertitude modélisant les perturbations du système  $V_{modele}$  :

$$[X_{k|k-1}^{(b)}] = A_{int}[X_{k-1|k-1}^{(b)}] + [V_{modele}] \quad (2.34)$$

La position globale estimée de l'objet est alors calculée comme la somme pondérée des centres géométriques de toutes les boîtes prédites.

#### 2. Association de données :

La matrice de covariance de la prédiction  $P_{nuage}$  est calculée en combinant la dispersion des centres

des boîtes avec la moyenne de leurs largeurs (rayons au carré). L'incertitude totale devient  $S_k = P_{nuage} + R_{cov}$ . L'association est validée de manière standard si la distance calculée respecte la région de validation ( $d_M < 3,5$ ).

### 3. Phase de correction géométrique et vraisemblance :

Lorsqu'une mesure est validée, elle est transformée en une boîte d'observation  $[Y_k]$  encadrant l'erreur maximale du capteur. L'innovation n'est plus une simple distance, mais l'intersection géométrique stricte entre la position prédite de la boîte  $[Z_{box}]$  et l'observation  $[Y_k]$  :

$$[R_{box}] = [Z_{box}] \cap [Y_k] \quad (2.35)$$

Si l'intersection est vide, le poids de la boîte devient nul. Sinon, la vraisemblance (et donc le nouveau poids  $w_k^{(b)}$  de la boîte) est mise à jour proportionnellement au ratio des volumes :




FIGURE 2.13 – Évaluation de la vraisemblance par intersection stricte des boîtes d'intervalles.

### 4. Rééchantillonnage par subdivision (Subdivision Resampling) :

Si le nombre de boîtes effectives chute sous un seuil critique, un rééchantillonnage est déclenché. L'algorithme utilise donc la subdivision : cela consiste tout simplement à prendre une grande boîte (qui a une forte probabilité de contenir le déchet) et à la trancher en deux (ou plusieurs) boîtes plus petites le long de son côté le plus long.

Cette mécanique agit comme un véritable zoom : au lieu de garder une grande zone de recherche vague, le fait de découper la boîte permet au filtre de se resserrer et d'isoler de plus en plus précisément la véritable position de l'objet suivi.

## Chapitre 3 : Validation expérimentale

Ce dernier chapitre est dédié à l'évaluation pratique et à la validation de l'architecture logicielle proposée. À travers une campagne d'essais menée en conditions réelles à proximité du canal de Calais. Une analyse comparative approfondie permettra d'évaluer la robustesse des trajectoires et la fiabilité de la gestion des incertitudes selon l'approche employée (probabiliste classique ou ensembliste).

### 3.1 Environnement et protocole expérimental

L'ensemble du pipeline de détection et de suivi a été développé en s'appuyant sur l'environnement logiciel MATLAB, en exploitant des toolboxes spécialisées telles que la *Lidar Toolbox* et l'*Image Processing Toolbox*. L'architecture matricielle native de MATLAB permet un traitement vectorisé optimisé de la représentation tensorielle du LiDAR.

Afin de valider les algorithmes en conditions réelles, une campagne d'acquisition a été menée le long du canal de Calais. Le capteur *Ouster OS1 128* a été positionné au bord du plan d'eau, (voire Figure 3.1).

Trois objets flottants cylindriques ont été déployés dans la zone d'observation (identifiés par ID 1, ID 2 et ID 3) pour évaluer l'algorithme de détection. Ces objets étaient soumis aux conditions environnementales naturelles, notamment un courant marin dont la vitesse a été approximée empiriquement à environ 0,15 m/s, se déplaçant le long de l'axe  $-Y$  du repère LiDAR.



FIGURE 3.1 – Le canal de Calais avec les 3 objets suivis et la direction du courant.



## 3.2 Résultats expérimentaux de suivi et détection

L'objectif de cette section est d'évaluer qualitativement et quantitativement la capacité des quatre algorithmes développés à maintenir une piste stable sur les trois objets simultanément, malgré le bruit de surface. Afin de mener une analyse poussée, nous étudierons pour chaque filtre : la trajectoire spatiale (nuage de points), la vitesse moyenne des objets, ainsi que la décomposition des vitesses ( $V_x$ ,  $V_y$ ,  $V_z$ ) et de la décomposition de l'accélération ( $a_x$ ,  $a_y$ ,  $a_z$ ) l'objet ID 1.


### 3.2.1 Validation des méthodes probabilistes

#### 1. Filtre de Kalman classique

Comme le montre la trajectoire 3D (Figure 3.2c), le filtre de Kalman classique produit une trajectoire de faible variabilité : les écarts entre positions successives restent inférieurs à ceux des détections brutes, le filtre privilégiant le modèle de transition sur la mesure. Les normes du vecteur vitesse (Figure 3.2b) se stabilisent entre 0,12 et 0,25 m/s selon les objets, valeurs compatibles avec la dérive attendue sous l'effet du courant. L'analyse de l'objet ID 1 (Figure 3.2a) confirme que la composante transversale  $V_y$  estime bien le courant de 0,15 m/s.

a) Décomposition des vitesses ( $V_x$ ,  $V_y$ ,  $V_z$ ) de l'objet ID 1

b) Vitesses des objets



c) Trajectoire 3D estimée




d) Décomposition des accélérations ( $a_x$ ,  $a_y$ ,  $a_z$ ) de l'objet ID 1


FIGURE 3.2 – Analyse cinématique des estimations du Filtre de Kalman classique.

## 2. Filtre Particulaire classique

La trajectoire 3D (Figure 3.3c) présente une variabilité plus élevée : le bruit gaussien injecté à chaque prédiction se répercute sur la moyenne pondérée des particules. L'observation des vitesses (Figure 3.3a) met en évidence l'instabilité de cette méthode. Les zones ombrées, qui représentent la dispersion du nuage de particules, varient fortement. Lors d'une succession de non-détections, le nuage n'est plus recalé par aucune mesure et sa dispersion croît à chaque prédiction, jusqu'à ce que la région de validation devienne trop large pour discriminer la bonne détection au retour de l'objet.

a) Décomposition des vitesses ( $V_x$ ,  $V_y$ ,  $V_z$ ) de l'objet ID 1

b) Vitesses des objets



c) Trajectoire 3D estimée




d) Décomposition des accélérations ( $a_x$ ,  $a_y$ ,  $a_z$ ) de l'objet ID 1

FIGURE 3.3 – Analyse cinématique des estimations du Filtre Particulaire classique.


### 3.2.2 Validation des méthodes ensemblistes (par intervalles)

#### 3. Filtre de Kalman Ensembliste (UBIKF)

Le passage aux intervalles modifie le comportement du suivi. Sur la trajectoire (Figure 3.4c), on observe des ruptures de pente : à chaque instant d'estimation, l'intersection avec la boîte de mesure ramène brutalement l'état dans le domaine compatible avec l'observation. La robustesse du filtre apparaît sur la décomposition des vitesses (Figure 3.4a) : la largeur de la zone d'incertitude reste bornée et ne croît pas au fil des itérations, car  $P^+$  constitue une borne supérieure garantie. La composante  $V_y$  estime le courant de 0,15 m/s avec une faible dispersion autour de cette valeur.

a) Décomposition des vitesses ( $V_x$ ,  $V_y$ ,  $V_z$ ) de l'objet ID 1

b) Vitesses des objets



c) Trajectoire 3D estimée




d) Décomposition des accélérations ( $a_x$ ,  $a_y$ ,  $a_z$ ) de l'objet ID 1


FIGURE 3.4 – Analyse cinématique des estimations du Filtre de Kalman Ensembliste (UBIKF).

#### 4. Filtre Particulaire par Boîtes (Box Particle Filter)

Sur les graphiques de vitesse (Figures 3.5b et 3.5a), on observe des variations de forte amplitude sur un intervalle court. Ce comportement traduit le fonctionnement du filtre : lorsque l'objet n'est pas détecté, la boîte d'état est propagée sans être contrainte et sa largeur augmente. Dès qu'une détection est de nouveau associée, l'intersection avec la boîte de mesure réduit brutalement cette largeur, ce qui se traduit par un pic sur la vitesse recalculée. La composante  $V_y$  reste centrée sur 0,15 m/s tout au long du suivi.

a) Décomposition des vitesses ( $V_x$ ,  $V_y$ ,  $V_z$ ) de l'objet ID 1

b) Vitesses des objets



c) Trajectoire 3D estimée


d) Décomposition des accélérations ( $a_x$ ,  $a_y$ ,  $a_z$ ) de l'objet ID 1

FIGURE 3.5 – Analyse cinématique des estimations du Box Particle Filter (BPF).

### 3.3 Analyse cinématique détaillée (Objet ID 1)

Afin de comparer les performances, nous avons isolé l'objet **ID 1** pour analyser sa trajectoire 3D et la décomposition de sa vitesse.

#### 3.3.1 Comparaison spatiale

La superposition des trajectoires tridimensionnelles (Figure 3.6) confirme que les quatre filtres parviennent à suivre l'objet, mais avec des comportements géométriques différents. L'axe  $Z$  (vertical) montre des variations causées par le mouvement physique des vagues.

L'interprétation des trajectoires reflète la mécanique interne de chaque algorithme :

- **Filtre de Kalman classique** : La trajectoire (en rouge) présente les écarts inter-trames les plus faibles. Le modèle d'état met à jour la position de manière strictement linéaire selon la matrice de transition  $A$ , ce qui efface les petits mouvements réels de l'objet sur l'eau.

- **Filtre Particulaire** : La trajectoire (en bleu) présente des variations plus aléatoires. Cela s'explique par l'ajout du bruit gaussien lors de la phase de prédiction des particules.
- **Filtre UBIKF** : La trajectoire (en vert) montre des segments droits suivis de corrections nettes. Ces corrections géométriques proviennent de l'intersection mathématique stricte entre la boîte de prédiction et la boîte de mesure LiDAR.
- **Box Particle Filter (BPF)** : La trajectoire (en orange) reste contenue dans un volume englobant la mesure. En utilisant des boîtes d'intervalles plutôt que des points, le filtre conserve une marge d'erreur géométrique qui l'empêche de perdre l'objet lors d'une perte de détection.




FIGURE 3.6 – Comparaison des trajectoires 3D estimées pour l'objet ID 1.

### 3.3.2 Validation de la vitesse et de l'accélération

L'analyse de la décomposition de la vitesse ( $V_x$ ,  $V_y$ ,  $V_z$ ) permet de valider la cohérence physique de nos estimateurs (Figure 3.7).

La composante transversale  $V_y$  est particulièrement intéressante : tous les filtres estiment une vitesse moyenne d'environ 0,15 m/s vers l'axe  $-Y$ . Cette valeur calculée par les algorithmes correspond exactement à l'estimation empirique de la vitesse du courant dans le canal.

On remarque que la courbe du filtre particulaire par boîtes (orange) présente des variations de forte amplitude sur un intervalle court. Elles résultent du mécanisme de contraction décrit plus haut : pendant les phases de non-détection, les boîtes d'état s'élargissent ; dès qu'une mesure est associée,

la vitesse *backward* est recalculée à partir du déplacement réel et intersectée avec l'intervalle courant. Cette contraction ramène l'estimation dans le domaine compatible avec l'observation, ce qui produit les pics visibles.



FIGURE 3.7 – Décomposition des composantes de vitesse ( $V_x$ ,  $V_y$ ,  $V_z$ ) pour l'objet ID 1.




FIGURE 3.8 – Décomposition des composantes d'accélération ( $a_x$ ,  $a_y$ ,  $a_z$ ) pour l'objet ID 1.

### 3.4 Analyse critique des modèles

La gestion de l'incertitude est le cœur des algorithmes de suivi. Les Figures 3.9, 3.10 et 3.11 illustrent l'évolution des covariances de position ( $P_{11}$ ,  $P_{22}$ ,  $P_{33}$ ), de vitesse ( $P_{44}$ ,  $P_{55}$ ,  $P_{66}$ ) et d'accélération ( $P_{77}$ ,  $P_{88}$ ,  $P_{99}$ ) au cours du temps pour l'objet ID 1.




FIGURE 3.9 – Évolution des covariances de position pour l'objet ID 1.




FIGURE 3.10 – Évolution des covariances de vitesse pour l'objet ID 1.




FIGURE 3.11 – Évolution des covariances d'accélération pour l'objet ID 1.

L'intérêt scientifique de tester ces quatre filtres est de démontrer les limites des approches stochastiques classiques en milieu aquatique, et d'évaluer l'intérêt de l'analyse par intervalles. L'analyse des covariances permet de critiquer objectivement chaque modèle :

- **Filtre de Kalman classique (Baseline)** : La covariance converge rapidement vers une valeur asymptotique stable (ligne rouge). L'algorithme suppose un bruit gaussien constant. Ce modèle s'adapte peu aux pertes de détection imprévisibles de la surface de l'eau.
- **Filtre Particulaire classique** : la variance estimée décroît jusqu'à frôler zéro (courbe bleue). Ce comportement est la signature de la dégénérescence : le poids se concentre sur quelques particules, la covariance empirique du nuage n'est plus calculée que sur un effectif réduit et sous-estime donc l'incertitude réelle. Le filtre devient excessivement confiant dans une estimation qui peut être fausse, ce qui pourrait le fragiliser lors d'occlusions prolongées.
- **Filtre de Kalman Ensembliste (UBIKF)** : L'introduction des intervalles permet de calculer une **borne supérieure garantie** ( $P_{11}^+$ ). La courbe verte reste stable. L'incertitude ne diverge pas au fil des itérations.
- **Box Particle Filter (BPF)** : La courbe orange est hautement dynamique. Contrairement aux filtres probabilistes, la covariance d'innovation  $S$  du BPF est calculée en additionnant la dispersion spatiale des centres des boîtes avec la matrice de leurs largeurs intrinsèques (*rayons*). Ainsi, lorsque la piste est masquée, les boîtes grandissent, augmentant mécaniquement la covariance. Lors d'une redétection, le mécanisme de rééchantillonnage par subdivision (*subdivision resampling*) réduit fortement la taille des boîtes, faisant chuter l'incertitude. Le BPF est ainsi le modèle qui ajuste le plus directement dynamiquement son incertitude à la réalité physique du milieu marin.

### 3.5 Évaluation quantitative du suivi par la métrique de cardinalité

Au-delà de l'analyse qualitative des trajectoires et des covariances, l'évaluation rigoureuse d'un algorithme de suivi multi-objets nécessite le recours aux métriques quantitatives usuelles de la littérature. La première d'entre elles, l'erreur de cardinalité (*Cardinality Error*), vérifie la capacité de l'algorithme à estimer le bon nombre de cibles présentes dans la scène à chaque instant.

Si l'on note  $|X_t|$  le nombre réel de cibles à l'instant  $t$  et  $|\hat{X}_t|$  le nombre de pistes confirmées par l'algorithme, cette métrique s'écrit :

$$e_{card}(t) = \left| |X_t| - |\hat{X}_t| \right| \quad (3.1)$$

Dans notre protocole expérimental, le nombre réel de cibles est connu avec certitude, puisque nous avons nous-mêmes déployé trois objets flottants dans le canal, soit  $|X_t| = 3$  pour toute la durée de l'acquisition. Une piste est comptabilisée dans  $|\hat{X}_t|$  dès lors qu'elle est confirmée par le système, y compris lorsqu'elle se trouve momentanément en mode de prédiction pure (occlusion par une vague) : l'algorithme affirme en effet que la cible existe toujours, et doit donc être évalué sur cette affirmation.

| Filtre                     | Moy. $ \hat{X}_t $ | Err. moyenne | Trames exactes | Err. max |
|----------------------------|--------------------|--------------|----------------|----------|
| Filtre de Kalman classique | 3,04               | 0,10         | 92,1 %         | 3        |
| Kalman Ensembliste (UBIKF) | 2,94               | <b>0,06</b>  | <b>98,1 %</b>  | 3        |
| Filtre Particulaire        | 2,94               | <b>0,06</b>  | <b>98,1 %</b>  | 3        |
| Box Particle Filter (BPF)  | 2,96               | 0,07         | 96,8 %         | 3        |

TABLE 3.1 – Erreur de cardinalité des quatre algorithmes de suivi ( $|X_t| = 3$  cibles réelles).




FIGURE 3.12 – Évolution de la cardinalité estimée et de l'erreur associée pour les quatre filtres.

L'analyse du Tableau 3.1 montre que les quatre architectures estiment correctement le nombre de cibles sur la grande majorité de la séquence, entre 92,1 % et 98,1 % des trames. La moyenne

estimée, comprise entre 2,94 et 3,04, reste très proche des trois cibles réellement déployées, ce qui traduit l'absence de pistes parasites persistantes. L'écart entre les filtres demeure limité, la cardinalité dépendant avant tout de la qualité du module de détection et des règles de gestion du cycle de vie des pistes, identiques pour les quatre estimateurs.

L'erreur maximale de 3, commune aux quatre méthodes, correspond aux premières trames de la séquence, durant lesquelles aucune piste n'est encore confirmée. Il s'agit d'un artefact d'initialisation, et non d'une défaillance du suivi.

La Figure 3.12 permet de localiser l'origine des erreurs résiduelles. Elles se concentrent aux deux extrémités de la séquence : lors des premières trames, durant lesquelles aucune piste n'est encore confirmée, et en fin d'acquisition, lorsque les objets quittent progressivement la Région d'Intérêt et que les pistes sont maintenues en prédiction pure avant leur suppression définitive.

Sur la majeure partie de la séquence, les quatre filtres estiment correctement la cardinalité  $|\hat{X}_t| = 3$ , ce qui valide la robustesse de l'association de données face aux fausses détections générées par l'agitation de surface.

## Conclusion générale, retour d'expérience et perspectives

Ce projet de fin d'études, réalisé au sein du laboratoire LISIC, s'inscrit dans un contexte environnemental. L'objectif principal de ce stage consistait à concevoir, développer et valider expérimentalement une architecture logicielle robuste capable de détecter et de suivre des objets flottants à l'aide d'un capteur LiDAR 3D et d'une centrale inertielle (IMU).

Pour relever ce défi, nous avons développé un pipeline de perception complet sous l'environnement MATLAB. Dans un premier temps, le module de détection a montré toute son efficacité grâce à une correction dynamique d'inclinaison couplée à une méthode de segmentation par distance radiale adaptative. L'utilisation d'un seuil dynamique  $\tau$  a permis de s'affranchir du bruit stochastique généré par l'agitation de la surface de l'eau, permettant d'extraire des boîtes englobantes fiables.

Dans un second temps, le cœur de notre étude s'est porté sur le suivi multi-objets (MOT). L'environnement aquatique provoquant des masquages fréquents (occlusions dues aux vagues) et des bruits de mesure non-gaussiens, nous avons implémenté et confronté quatre modèles d'estimation d'état. Les expérimentations menées en conditions réelles sur le canal de Calais ont validé nos hypothèses théoriques : si les filtres probabilistes classiques (Filtre de Kalman et Filtre Particulaire) parviennent à lisser les trajectoires, ils souffrent d'un excès de confiance (effondrement de la variance) qui pourrait les fragiliser lors de masquages prolongés.

À l'inverse, les approches ensemblistes basées sur l'analyse par intervalles se sont révélées particulièrement adaptées à ce milieu hostile. Le Filtre de Kalman Ensembliste (UBIKF) a montré une grande robustesse grâce à sa borne supérieure garantie. Le Filtre Particulaire par boîtes (Box Particle Filter - BPF) se distingue quant à lui sur la gestion de l'incertitude. En gérant l'incertitude géométrique par des intersections strictes de volumes et grâce à son mécanisme de rééchantillonnage par subdivision, le BPF permet d'encadrer la trajectoire des objets avec une représentation compacte (nécessitant seulement une dizaine de particules par objet).

## Organisation du travail et retour d'expérience

Le stage s'est déroulé sur sept mois, de mars à septembre 2026. La Figure 3.13 en retrace le déroulement.




FIGURE 3.13 – Déroulement du stage de mars à septembre 2026.

Les deux premières semaines ont été consacrées à la prise en main du capteur : compréhension du principe de mesure, exploration de la *Lidar Toolbox* de MATLAB, puis première acquisition permettant de visualiser un nuage de points en trois dimensions. L'étude bibliographique, engagée dès le début, s'est poursuivie tout au long du stage, les articles de référence sur le filtrage ensembliste n'ayant pris tout leur sens qu'au fur et à mesure de l'avancement des développements. Le choix de commencer par le milieu terrestre s'est révélé déterminant. Développer la détection puis le suivi dans les couloirs du laboratoire, où les objets sont immobiles et parfaitement identifiés, a permis de valider séparément chaque brique de la chaîne de traitement. Les erreurs rencontrées y étaient attribuables à l'algorithme seul, et non aux conditions d'acquisition. Les essais en extérieur ont ensuite introduit une première complexité, avec des objets de tailles variées et un arrière-plan encombré, avant le passage au milieu aquatique. Ce passage a constitué la principale difficulté du stage. L'absence de plan support, les fausses détections ont imposé de repenser la segmentation et la gestion du cycle de vie des pistes. C'est également ce qui a motivé le recours aux méthodes ensemblistes, dont l'intérêt n'apparaît pleinement qu'en présence d'un bruit borné mais mal caractérisé statistiquement. Sur le plan méthodologique, ce stage m'a appris la valeur d'une validation progressive. Chercher à traiter directement le cas marin aurait rendu tout diagnostic impossible, faute de pouvoir distinguer une erreur d'implémentation d'une difficulté propre au milieu.

## Perspectives d'évolution

Bien que les résultats obtenus confirment la viabilité de notre approche, ce travail ouvre la voie à plusieurs perspectives de développement :

- **Fusion avec l'information colorimétrique :** la nouvelle génération de capteurs Ouster (OS1 Rev 8) intègre une voie RGB nativement alignée sur la grille des faisceaux laser. Chaque cellule de la matrice porterait alors, en plus de la distance  $\rho$ , une information de couleur. Celle-ci serait exploitable à deux niveaux : en détection, pour discriminer un déchet coloré d'un reflet sur l'eau et ainsi réduire les fausses détections en amont du suivi ; en association, comme critère complémentaire à la distance de Mahalanobis lorsque plusieurs cibles évoluent à proximité, ce qui limiterait les échanges d'identifiants.
  
- **Classification par Intelligence Artificielle :** Actuellement, le système détecte des obstacles génériques. Coupler notre segmentation radiale avec un réseau de neurones profond opérant sur des nuages de points 3D (comme *PointNet* ou *PointPillars*) permettrait de classifier la nature de l'objet (plastique, bois, bouée) avant sa collecte.

# Bibliographie

- [1] F. Wang, Y. Liu, S. Hao et al., *A Review of Marine Obstacle Detection Techniques for Unmanned Surface Vehicles*, Journal of Marine Science and Engineering, vol. 10, n°1, p. 112, 2022.
- [2] Y. Cheng, M. Jiang, J. Zhu et Y. Liu, *USVInland : A Multimodal Dataset for USV Perception in Inland Waters*, IEEE Robotics and Automation Letters, vol. 6, n°2, pp. 2807–2814, 2021.
- [3] R. E. Kalman, *A new approach to linear filtering and prediction problems*, Journal of Basic Engineering, vol. 82, pp. 35–45, 1960.
- [4] M. S. Arulampalam, S. Maskell, N. Gordon et T. Clapp, *A tutorial on particle filters for online nonlinear/non-Gaussian Bayesian tracking*, IEEE Transactions on Signal Processing, vol. 50, n°2, pp. 174–188, 2002.
- [5] J. Xiong, C. Jauberthie, L. Travé-Massuyès et F. Le Gall, *Fault Detection using Interval Kalman Filtering enhanced by Constraint Propagation*, Proceedings of IEEE 52nd Annual Conference on Decision and Control (CDC), pp. 490–495, 2013.
- [6] T. A. Tran, C. Jauberthie, L. Travé-Massuyès et Q. H. Lu, *An Interval Kalman Filter enhanced by lowering the covariance matrix upper bound*, International Journal of Applied Mathematics and Computer Science, vol. 31, n°2, pp. 259–269, 2021.
- [7] F. Abdallah, A. Gning et P. Bonnifait, *Box particle filtering for nonlinear state estimation using interval analysis*, Automatica, vol. 44, n°3, pp. 807–815, 2008.
- [8] M. Fnadi et R. Lherbier, *Interval Particle Filter for LiDAR-Based Object Tracking*, Conference SCAN 2025, 22–26 sept. 2025, Oldenburg, Allemagne.
- [9] The MathWorks Inc., *MATLAB R2024b — Lidar Toolbox, Image Processing Toolbox*, Natick, Massachusetts, 2024. <https://www.mathworks.com>
- [10] S. M. Rump, *INTLAB - INTerval LABoratory*, In Developments in Reliable Computing, Kluwer Academic Publishers, Dordrecht, pp. 77–104, 1999. <http://www.ti3.tu-harburg.de/rump/>
- [11] Ouster Inc., *OS1 Series User Manual*, 2023. <https://ouster.com>